Aula 1 - Introdução ao R

Vitor Rios

10 de outubro de 2017

Bem vindos

Cronograma

Dia 1 - 21/11 - Introdução e como usar o R e Rstudio, boas práticas de programação
Dia 2 - 22/11 - Criando e e manipulando dados
Dia 3 - 23/11 - Trabalhando com arquivos externos
Dia 4 - 28/12 - Noções de programação
Dia 5 - 05/12 - Gráficos
Dia 6 - 06/12 - Análise exploratória e funções matemáticas
Dia 7 - 07/12 - Análise exploratória e funções matemáticas
Dia 8 - 12/12 - Análise estatística básica
Dia 9 - 13/12 - Versionamento de código: noções de git
Dia 10 - 14/12 - Programação para iniciantes, Função final

Aulas: teoria (1 a 2 h) + prática (wiki do curso) Avaliação: exercícios e constução de uma função (entrega 2 semanas após fim da disciplina)

O que é o R?

- R é uma linguagem de programação voltada para análises estatísticas e manipulação de dados
- RStudio é um ambiente de desenvolvimento integrado (IDE) que extende as capacidades do R e facilita o uso

Jeito R de ser

- Praticidade
- Reprodutibilidade
- Simplicidade (sim, você leu direito)
- Cooperação

Ao fazer o tratamento e análise dos dados dentro do R, você não altera os dados originais, e pode reproduzir tudo, bastando ter o script e os dados originais. Não é necessário nem salvar os gráficos!

Porque Usar R?

- Uma vastidão de pacotes de análises prontas

CRAN Task Views

Bayesian	Bayesian Inference
ChemPhys	Chemometrics and Computational Physics
ClinicalTrials	Clinical Trial Design, Monitoring, and Analysis
Cluster	Cluster Analysis & Finite Mixture Models
DifferentialEquations	Differential Equations
Distributions	Probability Distributions
Econometrics	Econometrics
Environmetrics	Analysis of Ecological and Environmental Data
ExperimentalDesign	Design of Experiments (DoE) & Analysis of Experimental Data
ExtremeValue	Extreme Value Analysis
Finance	Empirical Finance
FunctionalData	Functional Data Analysis
Genetics	Statistical Genetics
Graphics	Graphic Displays & Dynamic Graphics & Graphic Devices & Visualization
HighPerformanceComputing	High-Performance and Parallel Computing with R
MachineLearning	Machine Learning & Statistical Learning
MedicalImaging	Medical Image Analysis
MetaAnalysis	Meta-Analysis
Multivariate	Multivariate Statistics
NaturalLanguageProcessing	Natural Language Processing
NumericalMathematics	Numerical Mathematics
OfficialStatistics	Official Statistics & Survey Methodology
Optimization	Optimization and Mathematical Programming
Pharmacokinetics	Analysis of Pharmacokinetic Data
Phylogenetics	Phylogenetics, Especially Comparative Methods
Psychometrics	Psychometric Models and Methods
ReproducibleResearch	Reproducible Research
Robust	Robust Statistical Methods
SocialSciences	Statistics for the Social Sciences
Spatial	Analysis of Spatial Data
SpatioTemporal	Handling and Analyzing Spatio-Temporal Data
Survival	Survival Analysis
TimeSeries	Time Series Analysis
WebTechnologies	Web Technologies and Services
gR	gRaphical Models in R

Figure 1: CranTaskView

- Além disso, o R tem **Interfaces amigáveis que não precisam de programação**
  - RCommander <- fácil acesso às análises principais
  - Action <- análises integradas ao Excel
  - RStudio <-ambiente completo de programação
- Possibilidade de programar suas próprias análises, de acordo com suas necessidades
- Integração com outros softwares
  - GIS
  - Git <– **Salvação da humanidade**
  - Excel
  - C++
  - Python
  - Esta aula foi feita em R no RStudio

Primeiros passos no R

Abrir o RStudio

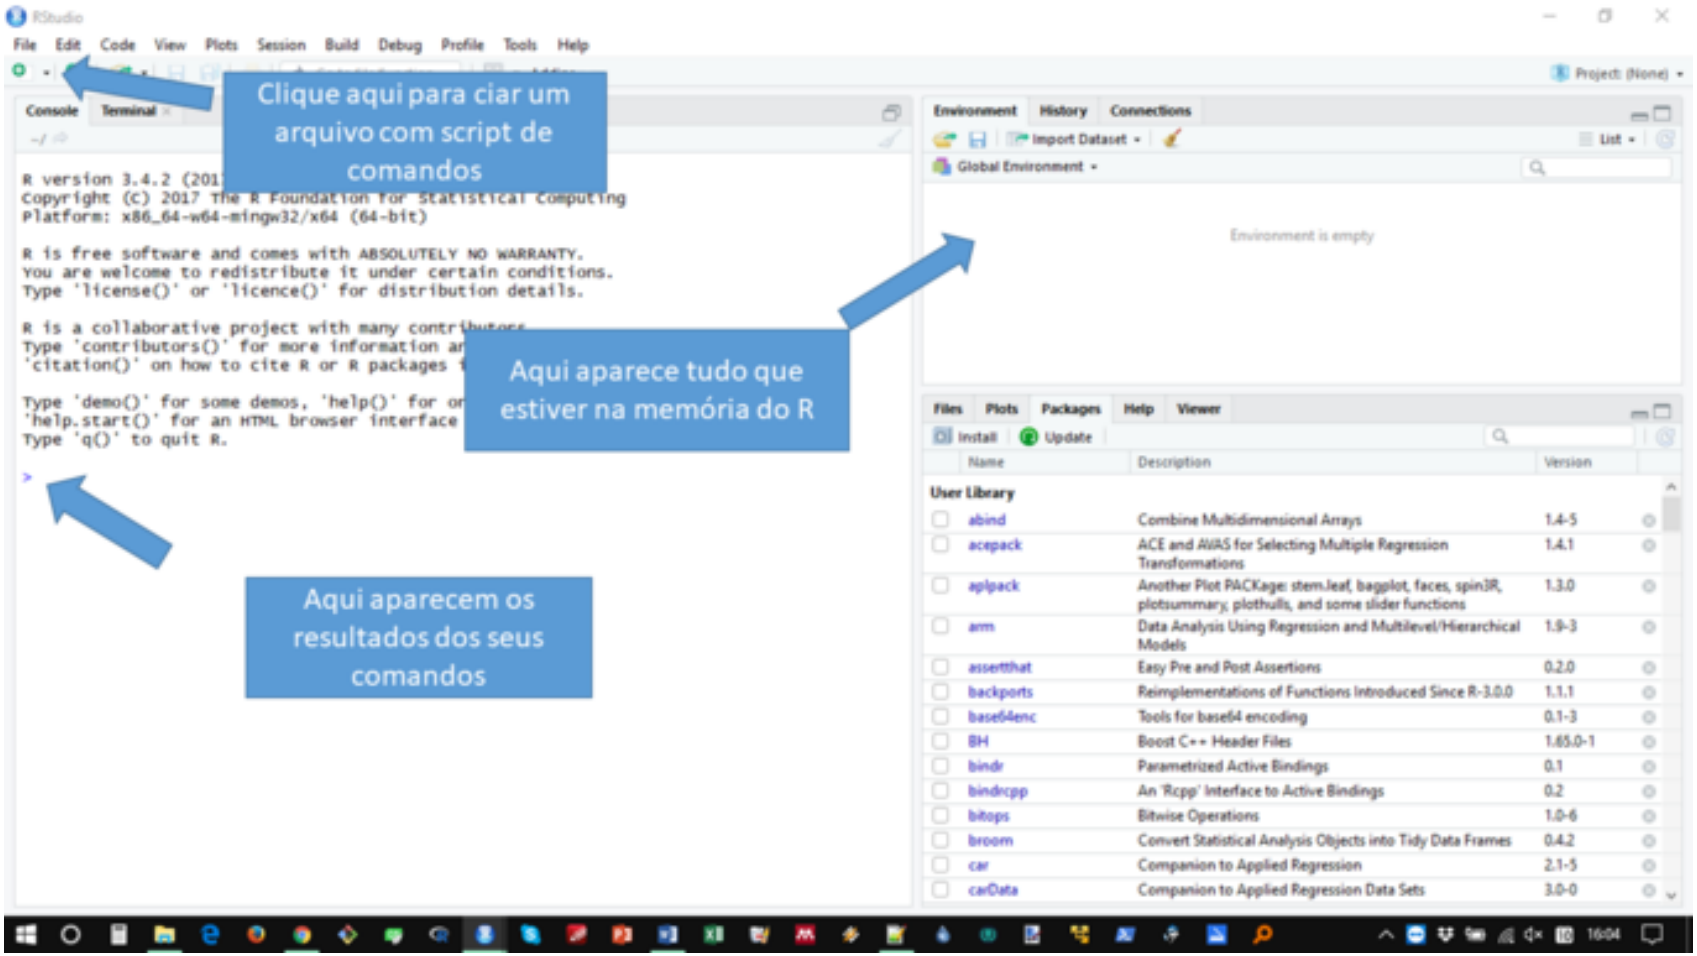

Figure 2:

No RStudio

Vantagens do RStudio

Note que o RStudio muda automaticamente as cores do código. Isto é chamado `syntax highlighting`, e serve pra facilitar a leitura. O que cada cor quer dizer?

O Rstudio também insere automaticamente um `)`, `}` ou `]` quando você digita `(`, `{`, ou `[`, o que diminui a maior parte dos erros de digitação

Digite o comando abaixo na aba console, onde está o caractere `>` , e depois tecle **enter**

```
4 + 12
```

```
## [1] 16
```

O resultado aparece logo abaixo, na própria aba, em cor diferente

O R é uma calculadora completa, tente várias combinações.

Qualquer texto após # é ignorado pelo R

```
1 + 1  # soma
```

```
## [1] 2
```

```
3 - 74 ## subtração
```

```
## [1] -71
```

```
4 * 12 ## multiplicação
```

```
## [1] 48
```

```
3 / 7 ## divisão
```

```
## [1] 0.4285714
```

O R também aceita comandos mais complicados

```
pi ^ 2 # potência
```

```
## [1] 9.869604
```

```
((4 * 7) + 45) / 2
```

```
## [1] 36.5
```

O que está dentro dos parênteses é avaliado de dentro para fora, e o resultado é usado para a operação seguinte, e assim por diante

Logaritmos, exponenciações, raízes

```
log(10, base=2)
```

```
## [1] 3.321928
```

```
exp(1)
```

```
## [1] 2.718282
```

```
sqrt(2)
```

```
## [1] 1.414214
```

Funções

Quando temos um nome seguido de parêntese com alguma coisa dentro, temos uma **função**
Função é um conjunto de comandos que faz uma operação em um objeto
`sqrt(x)` calcula a raiz quadrada de x
Funções podem ter opçoes, chamadas argumentos

```
log(10, base=2)
```

calcula o logaritmo de 10 na base 2

Quase tudo que você vai usar no R são funções

Muito cuidado com a digitação: para o R, maiúsculas e minúsculas são diferentes, e um espaço no meio da palavra atrapalha tudo

O R é burro, qualquer erro de digitação faz com que ele não encontre o que você procura

Ajuda das funções

você pode pedir socorro ao R em qualquer momento

```
?log()
?exp()
?plot()
help(library)
```

As funções geralmente vem em conjuntos especializados voltados para alguma análise, chamados de *pacotes*

Outros lugares para pedir ajuda

Quase todos os problemas que você tem com R, alguém já teve e resolveu

Google <- busque por "R manova" ou "R phylogenetics" ou "R cluster analysis", etc.
Stack Overflow <- geralmente é o primeiro resultado do Google

Quando o R der erro, copie a mensagem e cole no Google!

CRAN

o *Comprehensive R Archive Network* é o repositório central oficial de pacotes do R. Para instalar um pacote do CRAN, usamos o comando install.packages("nome",repositório)

```
install.packages("igraph", repos=http://nbcgib.uesc.br/mir
```

ou no RStudio, clicamos em `Install` na aba `Packages`

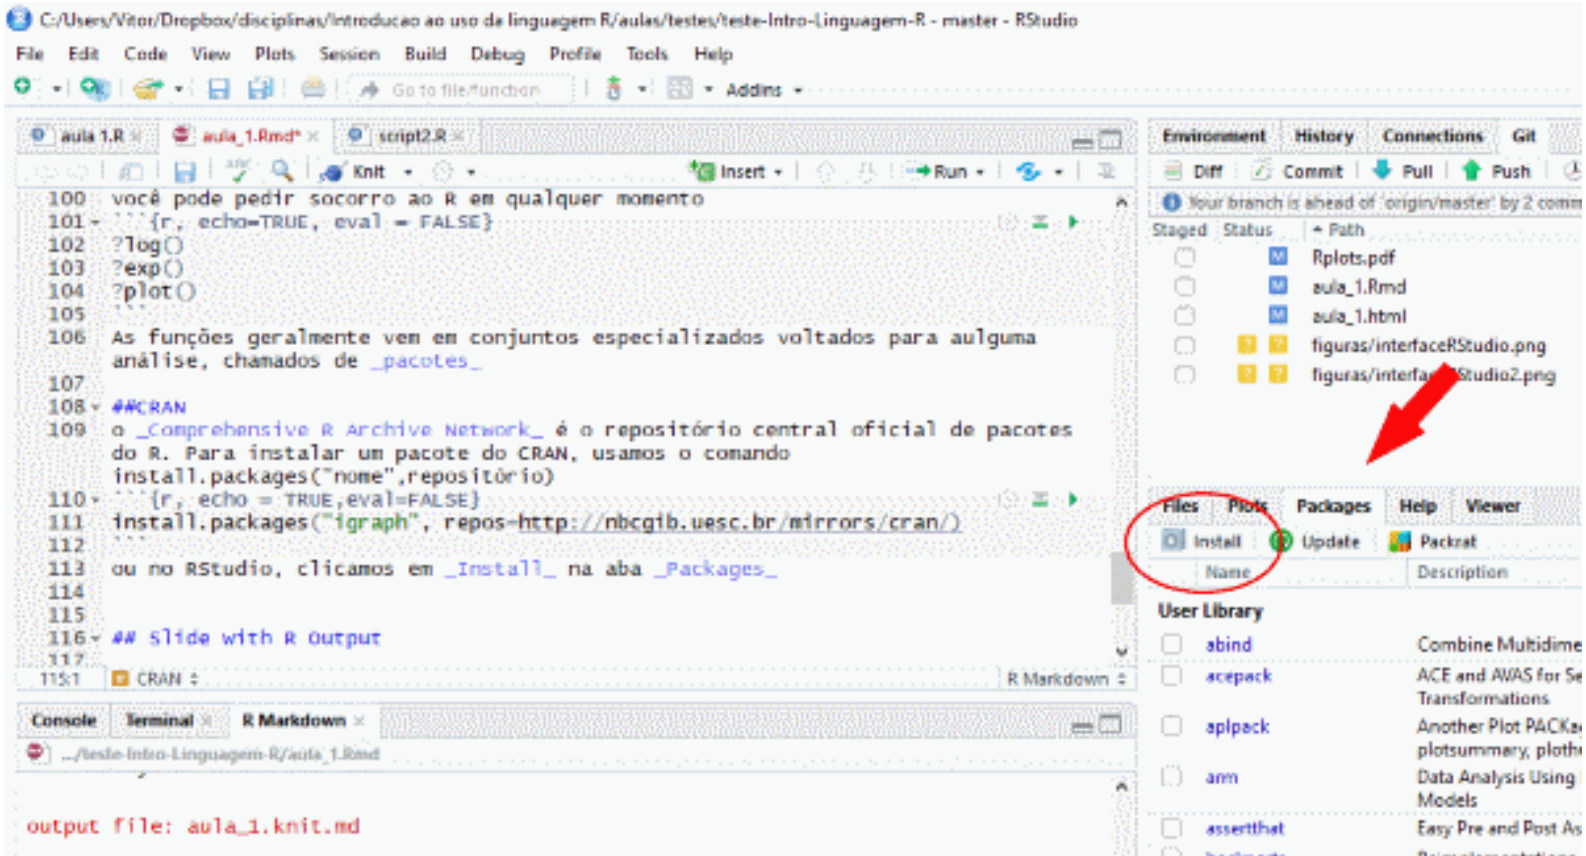

Para usar um pacote

```
library(igraph)
```

```
##
## Attaching package: 'igraph'
```

```
## The following objects are masked from 'package:stats':
##
##     decompose, spectrum
```

```
## The following object is masked from 'package:base':
##
##     union
```

agora as funções do `igraph` estão disponíveis para serem usadas

Dados e variáveis

R é uma linguagem de manipulação de objetos

No R, podemos criar caixas para guardar coisas que iremos usar depois, que chamamos de `variáveis`, ou `objetos`
Para isso usamos o sinal = ou <-. Pense na expressão `a = 10` como `o objeto a recebe o valor 10`

<- existe por motivos de compatibilidade com teclados que nao possuíam = (lá dos tempos jurássicos da computação). Use =

```
pote.de.sorvete = "feijão"
```

Na linha acima o R interpreta o que está dentro das apas como texto, e guarda esse valor dentro de um pedaço da memória que recebe o nome `pote.de.sorvete`.

O nome das variáveis não deve conter espaços, acentos,ou caracteres especiais como ç, ~, !, ?, /, |, +, , ^,,,'
** Ao digitarmos `pote.de.sorvete` no console, o R nos mostra o

Escolha nomes que façam sentido para suas variáveis

Lembre que você vai ter de ler seus códigos depois, e advinhar o que você quis dizer com `a`, `aa`, `x`, `X`, `a7589`, `MyVar` e outras bizarrices que pareciam fazer sentido.

Aproveite que o RStudio tem autocompletar!

Para trocar o que está dentro dessa variável, basta usar o $=$ novamente

```
pote.de.sorvete = "sorvete"
pote.de.sorvete
```

```
## [1] "sorvete"
```

Porque o código baixo nao funciona?

```
pote .de.sorvete = "chuchu"
```

Para ver o que tem na memória do R, use o comando `ls()`

```
ls()
```

```
## [1] "pote.de.sorvete"
```

No RStudio, podemos ver o conteúdo dos objetos que criamos na aba “Environment”

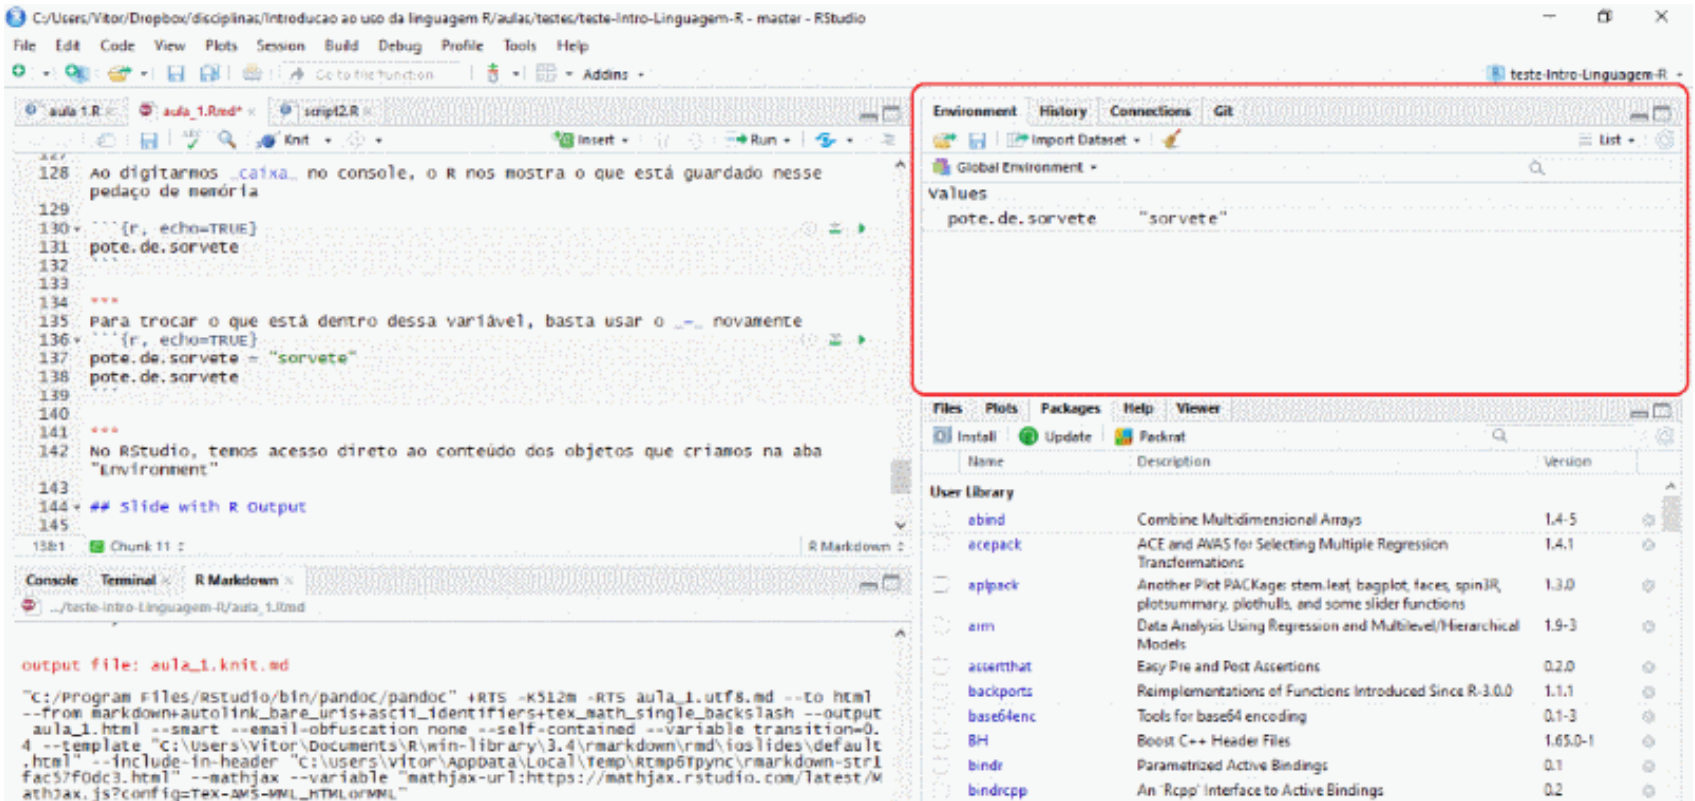

Variáveis também podem guardar conjuntos de dados

Chamamos estas variáveis de `vector` ou `vetor`. Criamos elas com a função `combine`, `c()`

```
geladeira = c("sorvete", "cebola", "agua", "miojo", "macar
geladeira
```

```
## [1] "sorvete"          "cebola"           "agua"
## [4] "miojo"            "macarrão"         "pacote.de.
```

Vetores só guardam objetos iguais: ou texto, ou números, nunca os dois juntos
Veja o que as funções `seq()` e `rep()` fazem!

Vetor é a unidade básica do R

Quase todas as funções do R são baseadas em manipulação de vetores

```
peso.real = c(100, 45, 77, 60)
peso.no.perfil = c(70, 50, 60, 55)
quilos.omitidos = peso.real - peso.no.perfil
quilos.omitidos
```

```
## [1] 30 -5 17  5
```

Ao somar, multiplicar, subtrair ou dividir vetores, o R pega os valores na mesma posição e faz a operação em questão

regra da reciclagem Quando um vetor é menor que o outro, o R repete o vetor menor até completar o maior

```
peso.real = c(100, 45, 77, 60, 50, 77.5)
ganho.apos.almoco = c(2, 5.3)
peso.gordo= peso.real + ganho.apos.almoco
peso.gordo
```

```
## [1] 102.0  50.3  79.0  65.3  52.0  82.8
```

Sempre confira o tamanho dos seus vetores!

Tamanho e conteúdo dos vetores

Função `length()` retorna o tamanho do vetor

```
peso.real = c(100, 45, 77, 60, 50, 77.5)
length(peso.real)
```

```
## [1] 6
```

Para acessar o elemento `i` do vetor, use `nome[i]`

```
peso.real = c(100, 45, 77, 60, 50, 77.5)
peso.real[3]
```

```
## [1] 77
```

Dataframes

Dataframes são o formato de tabela mais comum do R. No dataframe você pode ter colunas com tipos de dados diferentes, como numérico e texto.
Para criar o dataframe, podemos unir 2 ou mais vetores usando a função `data.frame()`

```
vetor1=LETTERS
vetor2=1:26
dados=data.frame(x=vetor1,y=vetor2)
class(dados)
```

```
## [1] "data.frame"
```

As colunas do dataframe podem ter nomes:

```
vetor3=letters
vetor4=26:1
nomesColunas= c("Letras","Numeros")
dadosNomeados=data.frame(vetor3,y=vetor4)
```

Acessando dados no dataframe

Existem dois jeitos principais de acessar dados em um dataframe: colchetes `[]` ou cifrão `$`
Isto se chama `indexação`:
dataframe[linha, coluna]

```
dadosNomeados[3,2]
```

```
## [1] 24
```

dataframe$nomeDaColuna

```
dadosNomeados$Numeros
```

```
##  [1] 26 25 24 23 22 21 20 19 18 17 16 15 14 13 12 11 10
## [24]  3  2  1
```

você também pode usar ambas notações:
dataframe$nomeDaColuna[linha]

Indexação

O colchete aceita também vetores como índice, incluindo vetores lógicos (sequencias de TRUE / FALSE)

```
Idade = c(3.0, 4.0, 5.0, 6.0, 8.0, 9.0, 10.0, 11.0, 12.0, 1

Idade[c(5, 4, 1, 10, 12)]
```

```
## [1]  8  6  3 14 16
```

```
Idade > 6 # retorna um vetor lógico dizendo se cada element
```

```
##  [1] FALSE FALSE FALSE FALSE  TRUE  TRUE  TRUE  TRUE  TR
## [12]  TRUE  TRUE
```

```
Idade[ Idade> 6 ] #retorna um vetor com todos os elementos
```

```
## [1]  8  9 10 11 12 14 15 16 17
```

Matrix

Matrizes são tabelas cujas colunas possuem apenas um tipo de dado, seja numerico ou texto. Podem ser criadas com as funções `matrix`, `cbind`, ou `rbind()`

Array

Array são estruturas de dados com mais de duas dimensões. pensando no vetor como uma linha, uma dataframe seria uma folha de papel, e o array com 3 dimensões seria o equivalente a um caderno, várias folhas empilhadas. Podemos também ter arrays com 4 ou cinco dimensões, que podemos fazer analogia com uma prateleira de cadernos, uma estante com várias prateleiras, e assim por diante.